

Uzaktan Fotopletismografi ile Deepfake Video Tespiti Üzerine Bir İnceleme

An Overview of Deepfake Video Detection Using Remote Photoplethysmography

Berkay YILMAZ
Mekatronik Mühendisliği Bölümü
Bursa Teknik Üniversitesi
Bursa, Türkiye
berkayilmaz_@outlook.com

Saffet VATANSEVER
Mekatronik Mühendisliği Bölümü
Bursa Teknik Üniversitesi
Bursa, Türkiye
saffet.vatansever@btu.edu.tr

Özetçe—Derin öğrenme yöntemleri kullanarak gerçeğe oldukça yakın videolar üretme yeteneğine sahip deepfake teknolojisi; sinema ve televizyon prodüksiyonları, eğitim, sosyal medya uygulamaları, sanat, moda ve sanal asistanlar da dâhil olmak üzere insanlığa hizmet eden geniş bir kullanım alanına sahiptir. Ancak, bu teknoloji, manipülatif içerikler vasıtasıyla potansiyel kötüye kullanım senaryolarını da beraberinde getirmektedir. Özellikle sahte haberler, kimlik sahteciliği, şantaj ve iftira gibi konularda bu teknoloji, yanlış bilgi yayılımını hızlandırabilmekte ve bireylerin mahremiyetine zarar verebilmektedir. Dahası, siyaset ve kamu güvenliği gibi kritik alanlarda, ciddi toplumsal ve hukuki sorunlara yol açabilmektedir. Bu bağlamda, deepfake videoların tespitine yönelik çözümlerin geliştirilmesi karşı konulamaz bir ihtiyaç haline gelmiştir. Literatürde, deepfake video tespiti konusunda geliştirilen yöntemlerin bir kısmı, sahte içerik üretme aşamasında istemsiz olarak oluşan dijital izlerin ve kalıntıların uzamsal ve frekans tabanlı analizine, bir kısmı da fizyolojik işaretlerin incelenmesine dayanmaktadır. Bireylerin cilt yüzeylerindeki gözle görülemeyen renk değişimlerinin analizine dayanan uzaktan fotopletismografi (remote photoplethysmography (rPPG)) tabanlı fizyolojik yöntemler, yüksek başarımla dikkat çekmektedir. Bu çalışmada, deepfake içerik üretiminde yaygın olarak tercih edilen derin öğrenme algoritmalarından Çekişmeli Üretici Ağ (Generative Adversarial Network (GAN)) ve Otokodlayıcı (Autoencoder (AE)) kullanımı ile oluşturulmuş sahte videoların tespitinde, rPPG tabanlı yöntemler ve etkisi incelenmiş, karşılaşılan teknik zorluklar ele alınmıştır.

Anahtar Kelimeler — *uzaktan fotopletismografi; derin öğrenme; sahte video; deepfake.*

Abstract—Deepfake technology, which can create remarkably realistic videos through deep learning techniques, has many applications that serve humanity, including cinema and television productions, education, social media applications, art, fashion, and virtual assistants. However, this technology also brings with it potential abuse scenarios through manipulative content. Particularly in cases like fake news, identity fraud, blackmail, and slander, it can hasten the dissemination of false information and violate people's privacy. Moreover, it may cause major legal and societal issues in crucial fields like politics and public security. In this context, developing solutions for detecting deepfake videos has

become imperative. While some methods developed in the literature to detect deepfake video are based on spatial and frequency-based analysis of digital traces and residues, which emerge intrinsically during the fake content production stage, some are based on examining physiological signs. Remote photoplethysmography (rPPG)-based physiological approaches, which analyze imperceptible color changes on the skin surfaces of individuals, have gained significant attention due to their high performance. This study examined rPPG-based techniques and their effectiveness in detecting fake videos made with Generative Adversarial Network (GAN) and Autoencoder (AE), two of the most popular deep learning algorithms used to produce deepfake content, and discussed the technical challenges encountered.

Keywords — *remote photoplethysmography; rPPG; deep learning; fake video; deepfake.*

I. GİRİŞ

Yapay zekâ alanındaki ilerlemelerle birlikte ortaya çıkan deepfake teknolojisi, ses, görüntü ve video manipülasyonunda en dikkat çeken uygulamalardan biridir. Gelişmiş derin öğrenme yöntemlerine dayanan bu teknoloji, gerçeğe son derece yakın sonuçlar üretebilmektedir. Bu özelliği sayesinde, eğlence sektöründen sağlık eğitimine kadar geniş bir uygulama yelpazesine sahiptir. Örneğin, sinema endüstrisinde eski oyuncuların dijital karakterlerinin yeniden oluşturulması, eğitim alanında tarihi figürlerle etkileşim sağlanması ve sanatçılara yeni görsel deneyimler yaşatılması gibi olanaklar sunmaktadır. Bu teknolojinin mevcut kullanım alanlarının sürekli olarak genişlemesi ve erişiminin kolaylaşması, kötü niyetli kişilerce de kullanımına zemin hazırlamaktadır. Bu durum, kitlesel dezenformasyon kampanyaları ve bireysel mağduriyetler gibi olumsuz sonuçların ortaya çıkmasına sebep olabilmektedir. Özellikle siyasi alanda, deepfake içeriklerin oluşturabileceği potansiyel tehditler endişe vericidir. Siyasi süreçler ve seçim kampanyaları sırasında, yanıltıcı videolar ve sahte konuşmalar, seçmenleri yanlış yönlendirerek kamuoyunu manipüle edebilir ve demokratik süreçleri ciddi şekilde tehlikeye atabilir. Bu tür müdahaleler, sadece bireyler üzerinde değil, aynı zamanda ulusal ve uluslararası düzeyde siyasi istikrar üzerinde de olumsuz etkiler doğurabilir [1], [2], [3], [4].

Deepfake teknolojisi, sunduğu avantajlara rağmen, hukuk ve toplumsal etik açısından önemli bir tartışma konusu haline gelmiştir. Hukuki açıdan, deepfake içeriklerin kötüye kullanılması durumunda kimlerin sorumlu tutulacağı ve mağdurların hangi haklara sahip olacağı gibi sorular, hukukun yeniden değerlendirilmesi gereken alanlarını işaret etmektedir [5], [6], [7]. Etik boyutta ise, deepfake içerikler gerçek ile kurgu arasındaki sınırları bulanıklaştırarak, toplumsal değerler üzerinde derin etkiler bırakabilir.

Tüm bu olumsuzluklar, deepfake video tespitine yönelik geliştirilen yöntemlerin önemini ve bu alanda yapılan ilerlemelerin gerekliliğini ön plana çıkarmaktadır. Bu alanda literatürde birçok çalışma yapılmış ve çeşitli yöntemler geliştirilmiştir. Bu yöntemlerin bir kısmı, deepfake video oluşturulması esnasında renk, çözünürlük, sınır çizgileri, desen vb. bileşenlerde oluşan kalıntıları uzamsal ve frekans tabanlı yaklaşımlar ile analiz etmeye yöneliktir. Bir diğer kısım ise, insanın kaş hareketleri, göz kırpması, kalp atışı gibi fizyolojik özelliklerinin çıkarılması ve bunların incelenmesine dayanır. Bu yöntemler arasında, ciltteki gözle görülemeyen renk değişimlerini kullanarak dolaşım sistemiyle ilgili bilgiler elde edilmesine imkân sağlayan uzaktan fotoplethysmografi (remote photoplethysmography (rPPG)) yönteminin kullanımına dayanan yaklaşımlar, deepfake video tespitindeki başarılı performansıyla dikkat çekmektedir. Bu çalışmada, rPPG teknolojisi kullanılarak deepfake video tespitine yönelik mevcut literatürdeki araştırmalar incelenmiş, bu yöntemlerin etkinliği ve karşılaşılan teknik zorluklar ele alınmıştır.

Bu çalışmanın kalan bölümleri şu şekilde düzenlenmiştir. Bölüm II’de, deepfake video oluşturulma tekniklerinden başlayarak, bu videoların tespitine yönelik literatürdeki başlıca yöntemler ele alınmıştır. Bölüm III’de, rPPG teknolojisi ele alınmış ve bu teknolojiyi kullanarak geliştirilen literatürdeki deepfake tespit yöntemleri değerlendirilmiştir. Bölüm IV’de, rPPG ile deepfake tespitinde kamera kalitesi, ışık yoğunluğu, kullanılan veri setleri ve zamansal tutarsızlıklar gibi faktörler başta olmak üzere karşılaşılan zorluklar ele alınmıştır. Son olarak Bölüm V’de, rPPG yönteminin deepfake tespitindeki genel etkisi özetlenmiş, bu alandaki mevcut eksiklikler vurgulanmış ve gelecekte daha güvenilir ve etkin sonuçlar elde edebilmek için yapılması gerekenler tartışılmıştır.


II. VİDEOLARDA DERİN SAHTECİLİK

A. Sahte Video Oluşturma

Deepfake teknolojisi, genellikle sahte video oluşturma ve içerik manipülasyonu amaçlarıyla kullanılmaktadır. Bu teknolojinin geliştirilmesinde derin öğrenme algoritmaları sıklıkla kullanılmaktadır. Deepfake video üretiminde Evrimsel Sinir Ağı (Convolutional Neural Network (CNN)) [8], [9], Tekrarlayan Sinir Ağı (Recurrent Neural Network (RNN)) [10], Çekişmeli Üretici Ağ (Generative Adversarial Network (GAN)) [11], [12], [13] ve Otokodlayıcı (Autoencoder (AE)) [14] yaygın olarak tercih edilen yöntemlerdendir. GAN ve AE’nin türevleri (StyleGAN, Variational AE, vs.) gerçeğe yakın videolar üretme konusunda en çok gelişme kaydedenlerdendir. Bu bölümde GAN ve AE yöntemleri üzerinde durulmaktadır.


GAN’lar biri üretici (generator) diğeri ayırıcı (discriminator) olmak üzere iki çekişmeli sinir ağından oluşur. Üretici ağı

görevi sahte veriler üretmek, ayırıcı ağı görevi ise bu sahte verileri birbirinden ayırmaktır (Şekil 1). Bu çekişmeli süreç her iki ağı da geliştirmeye yönelik bir yöntem sunarak daha gerçekçi deepfake videolar oluşturmaya olanak sağlar.



Şekil 1. GAN'ın genel mimarisi [44].

AE yöntemi, girdiyi bir gizli (latent) uzay temsiline sıkıştıran kodlayıcı (encoder) ve temsilden veriyi yeniden oluşturan bir kod çözücü (decoder) yapısından oluşur. AE, büyük veri kümeleri ile eğitilerek, verinin temel özelliklerini yakalamayı ve kopyalamayı öğrenir. Böylece gerçekçi sentetik medya oluşturulmasını sağlar. Otokodlayıcıların genel mimarisi Şekil 2’de gösterilmektedir.



Şekil 2. Kodlayıcı, gizli uzay ve kod çözücünden oluşan otokodlayıcı (autoencoder) mimarisi [45].

Deepfake video üretim teknikleri yüzün bütünsel sentezi (Entire Face Synthesis), özellik manipülasyonu (Attribute Manipulation), kimlik değişimi (Identity Swap) ve ifade değişimi (Expression Swap) olmak üzere dört ana işlev altında kategorize edilebilir [15], [16], [17]. Yüzün bütünsel sentezi; hiçbir gerçek kişiye ait olmayan, tamamen sentetik bir yüz oluşturmaya amaçlamaktadır. Bu tekniğe örnek olarak [18] incelenebilir. Özellik manipülasyonu, bir kişinin gerçek kimliğini değiştirmeden yaş, cinsiyet, göz rengi veya gözlük ekleme gibi belirli yüz özelliklerini değiştirmeyi kapsar. Kimlik değişimi yöntemi, bir kişinin yüzünü ve ses tonunu, bir başka kişinin yüz ve ses tonu ile tamamen değiştirme tekniğidir. Yalnızca yüzün değiştirilmesine odaklanan teknik yüz değiştirme (Face Swap) olarak adlandırılır. Kimlik değiştirme ve yüz değiştirme teknikleri, genellikle ünlü kişilerin deepfake görüntülerini oluşturmak amacıyla kullanılmaktadır. İfade değişimi, bir videodaki kişinin yüz ifadelerini başka bir videodan referans olarak değiştiren tekniklerdir. Kişinin orijinal videodakinden farklı duygular sergiliyormuş veya farklı kelimeler söylüyormuş izlenimi oluşturmaya hedefler.

B. Sahte Video Tespiti


Literatürde deepfake video tespiti için geliştirilen yöntemler, deepfake üreten yapay zekâların taklit etmekte zorlandığı dijital

özellikler ve fizyolojik işaretler üzerine temellendirilmiştir. Bu bağlamda, dijital özelliklere dayalı yöntemler, videolardaki uzamsal ve frekans tabanlı anormallikleri, yapay zekânın üretim sürecinde bıraktığı izleri ve dijital kalıntıları analiz ederken; fizyolojik işaretlere dayalı yöntemler, insan fizyolojisine özgü olan ancak yapay zekâ tarafından doğru şekilde taklit edilemeyen işaretlerin tespiti üzerine odaklanmaktadır.

1) Dijital Kalıntılara ve İzlere Dayanan Yöntemler

a) Uzamsal Tabanlı (Spatial-Based) Yöntemler

Sahte videoların uzamsal alanda (spatial domain) tespiti, popüler deepfake tekniklerindendir [19]. Uzamsal tabanlı yaklaşımlar, görüntüdeki piksel yoğunluk ve düzenlerindeki değişimleri analiz ederek manipülasyon izlerini tespit etmeyi amaçlar. Bu bağlamda, görüntüde meydana gelen bozulmalar, ışık etkileri, nesnelerin en-boy oranları, doku, renk, çözünürlük, sınırlar ve diğer görsel bileşenler ayrıntılı bir şekilde incelenmektedir [20]. Şekil 3'te manipüle edilmiş görüntülerde meydana gelen anormalliklere örnekler gösterilmiştir.



Şekil 3. Deepfake teknolojisi ile üretilmiş görüntülerdeki doğal olmayan dijital kalıntı ve iz örnekleri. a) Kaş ve alın bölgesindeki hatalı sınır çizgisi desenleri. b) Deepfake görüntüde oluşan hatalı cilt rengi tonu [46].

Uzamsal tabanlı yaklaşımlar, görüntü manipülasyonlarını tespit etmek için görsel bileşenleri detaylı bir şekilde incelerken, PRNU (Photo Response Non-Uniformity) analizi de bu alanda önemli bir araç olarak karşımıza çıkmaktadır. PRNU, kamera sensörlerinin üretimindeki kusurlardan kaynaklanan emsalsiz bir gürültü bileşenidir [21], [22]. PRNU sinyali, çekilen her görüntüde içsel bir imza olarak kabul edilebildiğinden, görüntü manipülasyonlarının tespitinde oldukça etkilidir. Koopman ve diğerleri [23] tarafından geliştirilen PRNU tabanlı deepfake tespit yöntemi, sabit bir alanın PRNU sinyalinin, bir video içindeki tüm karelerde tutarlı bir şekilde bulunması gerektiği prensibine dayanır. Eğer bu sinyalde belirgin bir tutarsızlık veya sapma tespit edilirse, bu durum, videonun manipüle edildiğine dair önemli bir kanıt olarak değerlendirilebilmektedir.


Derin sinir ağları (Deep Neural Networks (DNN)), yaygın olarak kullanılan uzamsal tabanlı deepfake tespit yöntemleri arasındadır. Cozzolino ve arkadaşları [24], görüntülerdeki küçük bölgelerde ortaya çıkan doku farklılıkları ve yapısal düzensizlikler gibi yerel özellikleri derin sinir ağlarıyla entegre eden bir yöntem geliştirmişlerdir. Bu yaklaşım, manipülasyon sonrasında görüntüde kalan ince düzensizlikleri tespit etmede yüksek performans göstermiştir. Bayar ve arkadaşları [25]

manipüle edilmiş görüntüleri tespit etmek için yeni bir evrimsel katman tasarlamış ve bu katmanla farklı manipülasyon türlerini geniş kapsamlı bir yaklaşımla tanımlamayı başarmışlardır. Bu yöntem, manipülasyon izlerini yakalamada etkileyici sonuçlar elde etmiştir. Zhou ve arkadaşları [26] ise, DNN tabanlı yüz sınıflandırma akışını (face classification stream), yerel gürültü kalıntıları ve kamera özelliklerini yakalamak için kullandıkları steganaliz tabanlı üçlü akışla (steganalysis feature based triplet stream) birleştirerek başarılı sonuçlar elde etmişlerdir. Son dönemde, deepfake video tespiti için Inception-ResNet [27], MesoNet [28], Kapsül Ağlar (Capsule Networks) [29] ve Xception [30] gibi gelişmiş ve karmaşık derin sinir ağları da kullanılmaktadır [31].

b) Frekans Tabanlı (Frequency-Based) Yöntemler

Deepfake tespiti alanında yapılan son çalışmalar, frekans tabanlı yaklaşımların bu alandaki doğruluk oranlarını önemli ölçüde artırdığını ortaya koymaktadır.

GAN tarafından üretilen deepfake videolar, frekans spektrumunda belirgin bozulmalar içermektedir. Bu bozulmalar, genellikle GAN'ların üretim sırasındaki örnek artırımı (upsampling) aşamalarında ortaya çıkar ve içerisinde orijinal görüntüde bulunmayan frekans özellikleri barındırır [32]. Bu nedenle, frekans tabanlı analizler, deepfake tespiti için etkili bir yöntem olarak öne çıkmaktadır. Dalgacık (Wavelet) analizi ve Kısa Zamanlı Fourier Dönüşümü (Short Time Fourier Transform (STFT)) gibi yöntemler, bu tür frekans alanı analizlerinde kullanılabilecek araçlar arasında yer almaktadır. Bu yöntemler, bir sinyalin frekans içeriği hakkında daha spesifik bilgiler sağlayarak deepfake'lerin daha yüksek doğrulukla tespit edilmesine olanak sağlayabilir [20]. Şekil 4'te gerçek bir yüz görüntüsü ile bu görüntüden üretilmiş sahte yüz görüntüsüne ait spektrumlar karşılaştırmalı olarak sunulmuştur.



Şekil 4. Gerçek bir yüz görüntüsü ve bu görüntü tarafından oluşturulan sahte bir yüz görüntüsünün spektrumları. Dama desenli kalıntılar yakınlaştırılarak gösterilmiştir. Gerçek ve sahte görüntülerin spektrumları arasında belirgin farklılıklar göz çarpmaktadır. Bu farklılıklar, üretici modelden kaynaklanan dama deseni kalıntılarının frekans alanındaki yansımalarıdır [47].

Literatürdeki, frekans tabanlı analizine dayanan deepfake tespit çalışmalarına örnek olarak, McCloskey ve Albright [33], GAN tarafından üretilen yüzlerin göz rengindeki değişimlerin frekans analizini gerçekleştirilmiş ve bu frekans değişimlerini deepfake videoların tespiti için kullanmışlardır. Yaptıkları çalışmada, deepfake videoları yüksek doğruluk ile tespit etmeyi başarmışlardır [20].

Frekans tabanlı yöntemler sıklıkla tercih edilse de bazı sınırlamaları bulunmaktadır. Düşük kaliteli videolarda, erişilebilir frekans spektrumunun daralması sebebiyle, deepfake videonun tespit edilebilmesi zorlaşmaktadır. Ayrıca, frekans tabanlı yöntemler, görüntü sıkıştırma ve yeniden yapılandırma gibi etkilere karşı yeterince dayanıklı değildir [19], [34]. Bu nedenle, frekans tabanlı yöntemlerin pratik uygulamalarda daha

etkili bir şekilde kullanılabilmesi amacıyla, bu yöntemlerin geliştirilmesi gerekmektedir.

2) Fizyolojik Tabanlı (Physiological-Based) Yöntemler

Fizyolojik tabanlı yaklaşımlar, deepfake videoların tespitinde yüz ifadeleri, göz kırpmaları hareketleri, kaş yapısı ve kalp atış hızları gibi fizyolojik verileri kullanır. Bu tür veriler, deepfake üretim algoritmalarının tam olarak taklit edemediği karmaşık süreçlere dayanması sebebiyle, deepfake videoların tespitinde oldukça etkilidir. Fizyolojik işaretler yardımıyla deepfake video tespitinde ait örnek bir uygulama Şekil 5'te verilmiştir.

Fizyolojik verilerden kaşlar ve kaş bölgesi, sentezlenmiş görüntülerde en çok etkilenen alanlardan biri olması sebebiyle, deepfake video tespitinde kullanımı oldukça önemlidir. Özellikle yüksek kaliteli deepfake videolarda, kaş bölgesindeki değişiklikler daha belirgin hale gelmektedir. Bu yöntemin etkili olabilmesi için, eğitilmiş model, bireylere ait biyometrik kayıtlara ihtiyaç duyar. Ünlü kişiler söz konusu olduğunda bu yöntem daha uygulanabilir hale gelmektedir. LightCNN, Resnet, DenseNet ve SqueezeNet gibi derin öğrenme modelleri, bu tür biyometrik tanımlama görevlerinde yüksek performans gösterme potansiyeline sahiptir [35].

Diğer bir fizyolojik veri olan göz kırpmaları hareketi, insan gözünde doğal bir davranış olup, zamanla tekrarlayan belirli bir ritme sahiptir. Ancak, Deepfake videolarda bu doğal ritmin doğru şekilde taklit edilmesi genellikle zordur. Göz kırpmaları tespiti için kullanılan yöntemler, gözün açık ve kapalı olduğu durumları ayırt etmek için CNN ve Uzun Süreli Tekrarlayan Sinir Ağı (Long-term Recurrent Convolutional Networks (LRCN)) modellerini kullanır. Bu modeller, göz kırpmaları hareketinin zamansal ilişkisini analiz eder ve böylece deepfake videoları tespit eder [35].


Deepfake video tespitinde, rPPG tabanlı fizyolojik yöntemler yüksek başarımla dikkat çekmektedir. rPPG genel olarak, kalbin kan pompalama döngüsüyle ciltte gerçekleşen küçük renk değişimlerinin bir sensör veya kamera ile yakalanıp analiz edilerek dolaşım sistemiyle ilgili bilgilerin elde

edilmesine dayanan bir yöntemdir [36]. Bu yöntemle elde edilen kalp atım hızı verileri, gerçek görüntüler ile manipüle edilmiş görüntüler arasında farklılıklar göstermektedir ve bu farklılıklar deepfake videoların tespitinde kullanılmaktadır. Bu doğrultuda, literatürdeki çalışmalardan, DeepFakesON-Phys [9] gibi derin öğrenme tabanlı modeller, fizyolojik sinyalleri kullanarak sahte yüz videolarını tespit etme konusunda etkili sonuçlar elde etmişlerdir.


III. UZAKTAN FOTOPLETİSMOGRAFİ İLE DEEPFAKE ANALİZİ

A. Uzaktan Fotopletismografi

Uzaktan fotopletismografi (rPPG), dolaşım sistemi ile ilgili bilgilerin temas gerektirmeden tahmin edilmesini sağlayan bir yöntemdir. rPPG algoritmaları, sinyalin elde edilme şekline göre ciltteki renk değişimlerini analiz eden ve hareket tabanlı yaklaşımlar olarak iki ana kategoriye ayrılmaktadır. Renk değişimine dayalı yöntemler, ciltteki kan akışına bağlı olarak meydana gelen ve gözle görülemeyen renk değişimlerini analiz eder. Kan damarları, her kalp atışıyla birlikte genişler ve daralır. Bu durum, cilt yüzeyinde renk değişimlerine neden olur. Renk değişimlerini analiz eden algoritmalar, kamera aracılığıyla cildin görüntüsünü yakalar ve elde edilen veriler üzerinden kalp atış hızını tahmin eder. Şekil 6'da bu yöntemin çalışma prensibini görselleştiren bir diyagram bulunmaktadır.



Şekil 6. Speküler ve dağınık yansımaları içeren, sadece dağınık yansımaların pulsatil bilgi içerdiği deri yansıması [49].



Şekil 5. Çifti ve arkadaşıları [48] tarafından fizyolojik işaretler kullanılarak deepfake videoların tespitine yönelik yapılan çalışmaya genel bakış. Gerçek ve sahte portre videolarının (a) belirli yüz bölgelerinden (b) fizyolojik sinyaller çıkarılır (c). Mekansal uyumu ve zamansal tutarlılığın hesaplanması için dönüşümler (d) uygulanır. Sinyal özellikleri, özellik kümeleri (e) ve PPG haritalarında toplanır, ardından bir olasılıksal gerçeklik sınıflandırıcı (f) ve bir CNN (g) eğitilir. Son olarak videonun gerçekliğini sınıflandırmak adına gerçeklik olasılıkları kümelendirir (h).

rPPG algoritmaları, genel olarak fizyolojik ölçüm zincirini oluşturan üç ana aşamaya bölünebilir: ham sinyal çıkarımı, pletismografik sinyalin tahmini ve kalp atış hızının belirlenmesi [37].

Sinyal çıkarım aşaması, rPPG algoritmalarının temel yapı taşdır. Bu aşamada, video karelerinden elde edilen verilerden anlamlı fizyolojik sinyaller elde edilir. Renk temelli yaklaşımlarda, yüz bölgesinde tanımlanan ilgili bölgedeki (region-of-interest (ROI)) piksellerin yoğunluklarının ortalaması alınarak sinyal çıkarılır. Hareket temelli yaklaşımlarda ise baş hareketleri izlenerek sinyal çıkarımı yapılır. Her iki yaklaşımda da elde edilen ham sinyal, filtreleme işlemleriyle gürültülerden arındırılarak daha temiz bir sinyal elde edilir [37]. Filtreleme işlemleri, alçak geçiren filtreler ile yüksek frekanslı gürültülerin bastırılmasını veya yüksek geçiren filtreler ile belirli frekans aralıklarındaki sinyallerin korunmasını içerir. Bu işlemler, sinyalin kalitesini artırarak algoritmanın genel performansını olumlu yönde etkiler [37].

rPPG algoritmalarında doğru donanım seçimi, fizyolojik sinyallerin elde edilebilmesini önemli ölçüde etkilemektedir. Örneğin insan kalp atış hızı dakikada 40-240 atım (ppm) olması sebebiyle kalp atış hızını doğru bir şekilde tespit edebilmek için video sensörlerinin en az 8 kare/saniye hızında çalışması gerekmektedir. Daha yüksek bir örnekleme hızı, daha hassas ve güvenilir verilerin elde edilmesini sağlar [38].

Algoritma düzeyinde, insan tespiti ve takibi, yüz ve yüz bölgelerinin tespiti gibi fonksiyonlar, fizyolojik sinyallerin doğruluğunu artırmak amacıyla kullanılmaktadır. Uzamsal bölgelerin seçiminden elde edilen zaman serileri, daha sonra kısa süreli spektrum analizi ile işlenir ve anlık kalp atış hızı tahmini yapılır [38].

Literatürde, rPPG teknolojisinin daha geniş ve zorlu koşullarda uygulanabilmesi için geliştirilmiş algoritmalar mevcuttur. Bu algoritmalar, sensör modaliteler ve algılama kanalları gibi çeşitli parametrelerin optimize edilmesi, aydınlatma gürültüsünün etkisinin azaltılması ve hareket eden kişiler üzerinde tutarlı sonuçlar alınabilmesi gibi konular üzerine geliştirilmiştir. Örneğin, yeşil (G) kanal, geniş mesafelerdeki ortam ışığı verileri için en güçlü pletismografik sinyali sağlar ve bu nedenle rPPG sistemlerinde yaygın olarak kullanılır [38].


rPPG sistemlerinin etkinliğini artırmak amacıyla yüz tespiti ve takibi, cilt tespiti ve baş hareketine dayalı rPPG gibi çeşitli teknikler geliştirilmiştir. Yüz işaretlerinin (landmark) doğru bir şekilde belirlenmesi, cilt tespiti ve fizyolojik sinyal analizinde kritik öneme sahiptir. Bununla birlikte, koyu ten rengine sahip deneklerde cilt pigmentasyonu nedeniyle sinyal-gürültü oranı düşebilir ve bu da fizyolojik sinyal analizini zorlaştırabilir. Buna karşın, baş hareketlerinden elde edilen sinyaller, doğrudan cilde erişim olmadığında bile rPPG sinyallerinin elde edilmesine olanak sağlar ve sistemlerin esnekliğini artırır [38].

B. Uzaktan Fotopletismografi Tabanlı Deepfake Video Tespiti

Deepfake tespitinde rPPG tabanlı yöntemler üzerine yapılan literatürdeki mevcut çalışmalar, birbirinden farklı algoritmalar kullanarak rPPG sinyallerinin analizini gerçekleştirmekte ve bu

analizler sonucunda etkili bir şekilde deepfake video tespiti sağlamayı amaçlamaktadır.

Ni ve arkadaşlarının [39] yaptığı çalışmada, rPPG sinyallerini Hızlı Fourier Dönüşümü (Fast Fourier Transform (FFT)) yöntemiyle işlemiş ve elde edilen zaman-frekans sinyalleri, Matris Görselleştirme Isı Haritaları (Matrix Visualization Heatmaps (MVHM)) oluşturmak için kullanılmıştır. Bu ısı haritaları daha sonra bir görüntü sınıflandırma ağına öğretilerek deepfake videoların tespit edilmesi amaçlanmıştır. FFT'nin kullanımı, zaman-frekans analizinin daha detaylı yapılmasına olanak tanımakta ve bu sayede deepfake videoların yüksek doğrulukla tespit edilmesini sağlamaktadır. Bu durum FFT ve dikkat mekanizmalarının deepfake tespitinde ne kadar etkili olduğunu ortaya koymaktadır. Çalışma için genel bir bakış Şekil 7'de gösterilmiştir.




Şekil 7. Ni ve arkadaşları [39] tarafından Fourier dönüşümü ile rPPG sinyal analizi kullanılarak geliştirilen deepfake tespit yöntemine genel bakış. Yüz videosu kareleri alınır (a), yüz tespiti yapılarak ilgili bölge (ROI) belirlenir (b), bu bölgeden rPPG sinyali çıkarılıp gürültü temizliği yapılır (c), ardından FFT ile frekans analizi gerçekleştirilir (d). rPPG sinyalleri ve ilgili FFT'lerle oluşturulan matris ısı haritası olarak görselleştirilir (e) ve deepfake tespiti için eğitilmiş modele giriş olarak verilir (f).

Qi ve arkadaşlarının [31] çalışması, rPPG sinyallerindeki normal kalp atış ritimlerinin deepfake videolarda bozulduğu varsayımına dayanmaktadır. Bu bozulma, deepfake videoları tespit etmek için güçlü bir gösterge olarak kabul edilmektedir. DeepRhythm yöntemi, Çift Uzamsal-Zamansal Dikkat Ağları (Dual-Spatial-Temporal Attention Networks) kullanarak farklı deepfake türlerine ve zorluk derecelerine karşı adaptasyon sağlayan bir model önermektedir. Bu yaklaşım, deepfake videolarındaki fizyolojik sinyal bozulmalarını izleyerek sahte içerikleri yüksek doğrulukla tespit edebilmektedir. Çalışmada yapılan deneyler, bu yöntemin farklı veri setlerinde yüksek bir genelleme yeteneği sunduğunu göstermektedir. Bu durum dikkat mekanizmalarının deepfake tespitinde ne kadar önemli bir rol oynadığını ortaya koymaktadır.

Hernandez-Ortega ve diğerlerinin [9] çalışması, kalp atış hızına dayalı bir deepfake tespit çerçevesi sunmakta ve rPPG sinyallerini analiz etmek için Evrimsel Dikkat Ağı (Convolutional Attention Network (CAN)) kullanmaktadır. CAN, video karelerinden hem uzamsal hem de zamansal bilgiyi çıkararak sahte videoları daha iyi tespit etmeyi hedefler. Bu çalışma, halka açık veri setleri üzerinde test edilmiş ve %98'in üzerinde eğri altındaki alan (Area Under the Curve (AUC))

değeri elde etmiştir. Bu sonuçlar, rPPG tabanlı yaklaşımların sahte videoların tespitinde ne kadar başarılı olduğunu bir kez daha doğrulamaktadır.

Çiftçi ve diğerleri [40], deepfake videoların tespit edilmesinin yanı sıra, bu videoların hangi modelle üretildiğinin tespiti üzerine de odaklanılmıştır. Çalışmada, rPPG sinyalleri kullanılarak sahte videoların hangi modelle oluşturulduğu oldukça yüksek doğruluk oranı ile tespit edilebilmiştir. Bu çalışmada kullanılan derin öğrenme tabanlı yaklaşımlar rPPG sinyallerindeki uzamsal ve zamansal kalıpları analiz ederek sahte videoların kaynağını belirlemede oldukça başarılı olmuştur. Yapılan çalışma Şekil 8’te görsel olarak özetlenmiştir.



Şekil 8. Çiftçi ve arkadaşları [40] tarafından biyolojik sinyaller kullanılarak deepfake videoların kaynak tespitine yönelik yapılan çalışmanın genel bir özeti. Gerçek videolar (a), çeşitli üreticiler (b) tarafından her bir üreticiye özgü kalıplar ile deepfakeler oluşturmak için kullanılır (c). Sistem yüzün ilgili bölgelerini (ROI) (d) ve fizyolojik sinyalleri (e) çıkararak, üretici kalıplarının uzamsal, zamansal ve frekans alanlarında yansıtıldığı PPG hücreleri (f) üretir. Ardından, (c) adımıyla oluşturulan herhangi bir videonun hem doğruluğunu hem de kaynağını sınıflandırmak amacıyla, PPG hücreleri üzerinde eğitim yapılır ve pencere başına tahminler birleştirilerek sonuca ulaşılır (g).

Wu ve arkadaşları [41] çalışmalarında, rPPG sinyallerinin çok ölçekli uzamsal-zamansal analizine dayalı bir tespit yöntemi önerilmiştir. Bu çalışmada, rPPG sinyallerinden elde edilen Çok Ölçekli Uzamsal-Zamansal (Multi-Scale Spatial-Temporal) PPG haritaları, Maske Yönlendirmeli Yerel Dikkat (Mask-Guided Local Attention (MLA)) modülü ve Zamansal Dönüştürücü (Temporal Transformer) kullanılarak analiz edilmiştir. MLA modülü, rPPG haritalarındaki benzersiz yerel kalıpları yakalarken Zamansal Dönüştürücü, bitişik rPPG haritalarının uzun mesafeli etkileşimlerini değerlendirmiştir. Bu iki aşamalı ağ, deepfake videoların tespitinde üstün bir performans sergilemiştir.

rPPG tabanlı deepfake tespit yöntemleri, deepfake video üretim algoritmalarının fizyolojik sinyalleri doğru bir şekilde taklit edememesi nedeniyle geleneksel tespit yöntemlerine kıyasla daha yüksek doğruluk oranlarına ulaşmaktadır. Fourier Dönüşümü, dikkat mekanizmaları ve derin öğrenme gibi tekniklerin kombinasyonu rPPG sinyallerinin zamansal ve uzamsal özelliklerini daha etkili bir şekilde analiz etmeye olanak tanımakta ve bu da deepfake videoların tespitinde önemli bir avantaj sağlamaktadır. Öte yandan, rPPG tabanlı deepfake video tespit yöntemlerinin, pratik uygulamalarda karşılaşılan zorluklar nedeniyle performans sınırlamaları bulunabilir. Bu

sınırlamaların aşılması ve yöntemin daha geniş bir uygulama yelpazesinde etkin bir şekilde kullanılabilmesi için geliştirilmesi gerekmektedir.

IV. UZAKTAN FOTOPLETİSMOGRAFI İLE DEEPFAKE TESPİTİNDEKİ ZORLUKLAR

rPPG tabanlı deepfake video tespitinin başarılı bir şekilde gerçekleştirilebilmesi için, her aşamanın hatasız bir şekilde yürütülmesi gerekmektedir. Sinyal çıkarım sürecinden tespit algoritmalarının uygulanmasına kadar tüm adımların kusursuz olması, tespit performansının yüksek olmasını sağlar. Aksi halde, süreçte meydana gelebilecek en ufak bir aksaklık, tespit doğruluğunu olumsuz yönde etkileyebilir.

rPPG teknolojisinin en önemli zorluklarından biri, kullanılan kameraların kalitesi ve teknik özellikleridir. Her ne kadar düşük maliyetli kameralar rPPG ölçümleri için yeterli olabilese de, kamera özelliklerinin rPPG sinyallerinin kalitesini doğrudan etkilediği iyi bilinmektedir [42]. Bu durum, tespit sürecinde güvenilir sonuçlar elde edebilmek için yüksek kaliteli görüntüleme donanımına duyulan ihtiyacı ortaya koymaktadır. Özellikle kameraların renk filtrelerinin spektral aralığı, görüntü çözünürlüğü, bit derinliği ve sensör gürültüsü gibi faktörlerin rPPG sinyallerinin doğruluğunu etkilediği belirtilmiştir [42]. Bu bağlamda, kamera ayarlarının manuel yapılması gerektiği, aksi takdirde otomatik ayarların (örneğin, otomatik pozlama, beyaz dengesi) rPPG sinyallerini bozabileceği ifade edilmektedir. Kamera özelliklerinin yanı sıra bu ayarların etkileri de dikkate alındığında rPPG tabanlı analizlerde optimum koşulların sağlanması kritik öneme sahiptir.

rPPG tabanlı deepfake tespitinde karşılaşılan bir diğer önemli zorluk kullanılan ışık kaynağının özellikleriyle ilgilidir. Işık yoğunluğu ve spektrumu, ölçüm sonuçlarını doğrudan etkileyebilmektedir. Yetersiz aydınlatma, cilt üzerinden geri yansıyan foton miktarını azaltarak rPPG sinyallerini zayıflatılabilmektedir. Ayrıca, ışık kaynağının kararlılığı da önemli bir faktör olarak karşımıza çıkmaktadır. Titreşen veya değişen ışık koşulları, rPPG sinyallerinde hatalara yol açabilmektedir [42]. Bu ışık kaynaklı zorluklar, rPPG tabanlı ölçümlerin doğruluğunu olumsuz etkileyebilir ve bu nedenle aydınlatma koşullarının stabil ve uygun olması gerekmektedir.

rPPG tabanlı tespit en karmaşık bileşenlerinden biri de cilttir. Cilt tonu, melanin miktarı ve cilt üzerindeki yağ dağılımı gibi faktörlerin rPPG sinyallerinin gücünü ve doğruluğunu etkileyebileceği bilinmektedir. Özellikle koyu tenli bireylerde, melanin içeriği nedeniyle rPPG sinyallerinin zayıfladığı ve bu nedenle sinyal-gürültü oranının düştüğü gözlemlenmiştir. Ayrıca cildin hareketi de rPPG sinyallerinin bozulmasına neden olabilmektedir. Vücut hareketleri, cilt üzerindeki yansıyan ışığı değiştirerek rPPG sinyallerinde bozulmalara yol açabilir [42]. Bu fizyolojik ve çevresel etkenler rPPG tabanlı tespitlerde dikkat edilmesi gereken önemli unsurlar arasında yer almaktadır.

Deepfake tespiti için geliştirilen yöntemlerin büyük bir kısmı derin öğrenme tekniklerine dayanmaktadır. Bu tekniklerin etkinliği ise büyük ölçüde geniş ve çeşitli veri setlerine bağlıdır. Ancak rPPG sinyallerinin kullanıldığı veri setlerinin sayısı ve kalitesi sınırlıdır. Çoğu veri seti kontrollü laboratuvar ortamlarında toplanmış olup, gerçek dünya koşullarını yansıtmaktan uzaktır. Bu durum geliştirilen modellerin gerçek

dünya uygulamalarında yetersiz kalmasına neden olabilmektedir [43]. Bu nedenle derin öğrenme tabanlı yöntemlerin daha geniş veri setleriyle desteklenmesi ve bu setlerin gerçek dünya koşullarını yansıtacak şekilde geliştirilmesi gerekmektedir.

Son olarak deepfake tespitinde karşılaşılan bir diğer zorluk, zamanlama tutarsızlıkları ve gerçek zamanlı tespit gereksinimidir. Çoğu mevcut yöntem bir videonun her bir karesini ayrı ayrı analiz etmekte olup, bu da zamansal tutarsızlıklara neden olabilmektedir. Gerçek zamanlı tespit, büyük bir ihtiyaç olmakla birlikte mevcut yöntemler bu ihtiyacı karşılayacak düzeyde değildir [20]. Bu sebeple deepfake ile mücadelede daha etkin ve zamansal tutarlılığı yüksek tespit yöntemlerinin geliştirilmesi önemlidir.

V. SONUÇ

Bu çalışmada, rPPG yönteminin deepfake tespitinde kullanımına yönelik literatürdeki mevcut çalışmalar ve rPPG ile deepfake tespitinde karşılaşılan zorluklar incelenmiştir. Yapılan çalışmalarda elde edilen yüksek doğruluk oranları, bu yöntemin deepfake video tespiti için son derece etkili bir çözüm sunduğunu göstermektedir. Bu çalışmalarda rPPG ile elde edilen sinyaller, FFT, Uzamsal-Zamansal Dikkat Ağları (Spatial-Temporal Attention Networks), MLA modülü ve Zamansal Dönüştürücü (Temporal Transformer) gibi yöntemlerle birlikte kullanılarak rPPG kullanmayan yaklaşımlara kıyasla oldukça başarılı sonuçlar elde edildiği görülmüştür. Ancak, rPPG tabanlı yöntemler başarılı sonuçlara rağmen, yapay zekâ teknolojilerinin gelişmesiyle gerçeğinden ayırt edilemeyecek seviyelere ulaşan deepfake içeriklerin tespitinde yetersiz kalabilmektedir. Bu bağlamda, deepfake tespitindeki performansı artırmak adına rPPG sinyalinin kamera kalitesi, ışık yoğunluğu ve cilt tonu gibi faktörlerin olumsuz etkilerinin minimize edilmesi, bununla birlikte deepfake tespiti için geliştirilen derin öğrenme modellerinin eğitiminde kullanılan veri setlerinin gerçek dünya koşullarını daha iyi yansıtacak şekilde iyileştirilmesi gerekmektedir.

KAYNAKLAR

- [1] N. Diakopoulos and D. Johnson, "Anticipating and addressing the ethical implications of deepfakes in the context of elections," *New Media Soc*, vol. 23, no. 7, pp. 2072–2098, 2021.
- [2] T. Dobber, N. Metoui, D. Trilling, N. Helberger, and C. De Vreese, "Do (microtargeted) deepfakes have real effects on political attitudes?," *Int J Press Polit*, vol. 26, no. 1, pp. 69–91, 2021.
- [3] M. Hamelers, T. G. L. A. van der Meer, and T. Dobber, "You won't believe what they just said! The effects of political deepfakes embedded as vox populi on social media," *Soc Media Soc*, vol. 8, no. 3, p. 20563051221116344, 2022.
- [4] C. Vaccari and A. Chadwick, "Deepfakes and disinformation: Exploring the impact of synthetic political video on deception, uncertainty, and trust in news," *Soc Media Soc*, vol. 6, no. 1, p. 2056305120903408, 2020.
- [5] B. Chesney and D. Citron, "Deep fakes: A looming challenge for privacy, democracy, and national security," *Calif. L. Rev.*, vol. 107, p. 1753, 2019.
- [6] M. A. Franks and A. E. Waldman, "Sex, lies, and videotape: Deep fakes and free speech delusions," *Md. L. Rev.*, vol. 78, p. 892, 2018.
- [7] E. Meskys, J. Kalpokiene, P. Jurcys, and A. Liaudanskas, "Regulating deep fakes: legal and ethical considerations," *Journal of Intellectual Property Law & Practice*, vol. 15, no. 1, pp. 24–31, 2020.
- [8] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros, "Image-to-image translation with conditional adversarial networks," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 1125–1134.
- [9] J. Hernandez-Ortega, R. Tolosana, J. Fierrez, and A. Morales, "Deepfakeson-phys: Deepfakes detection based on heart rate estimation," *arXiv preprint arXiv:2010.00400*, 2020.
- [10] S. Ö. Ark et al., "Deep voice: Real-time neural text-to-speech," in *International conference on machine learning*, 2017, pp. 195–204.
- [11] T. Karras, S. Laine, and T. Aila, "A style-based generator architecture for generative adversarial networks," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2019, pp. 4401–4410.
- [12] I. Perov et al., "DeepFaceLab: Integrated, flexible and extensible face-swapping framework," *arXiv preprint arXiv:2005.05535*, 2020.
- [13] T. Park, M.-Y. Liu, T.-C. Wang, and J.-Y. Zhu, "Semantic image synthesis with spatially-adaptive normalization," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2019, pp. 2337–2346.
- [14] M. K. Das, M. Kumar, I. K. Kapil, and R. K. Yadav, "Deepfake Creation Using Gans and Autoencoder and Deepfake detection," in *2023 2nd International Conference on Vision Towards Emerging Trends in Communication and Networking Technologies (ViTECoN)*, 2023, pp. 1–6.
- [15] Y. Mirsky and W. Lee, "The creation and detection of deepfakes: A survey," *ACM computing surveys (CSUR)*, vol. 54, no. 1, pp. 1–41, 2021.
- [16] L. Verdoliva, "Media forensics and deepfakes: an overview," *IEEE J Sel Top Signal Process*, vol. 14, no. 5, pp. 910–932, 2020.
- [17] R. Tolosana, R. Vera-Rodriguez, J. Fierrez, A. Morales, and J. Ortega-Garcia, "Deepfakes and beyond: A survey of face manipulation and fake detection," *Information Fusion*, vol. 64, pp. 131–148, 2020.
- [18] "This person does not exist." Accessed: Aug. 11, 2024. [Online]. Available: <https://thispersondoesnotexist.com>
- [19] F. Juefei-Xu, R. Wang, Y. Huang, Q. Guo, L. Ma, and Y. Liu, "Countering malicious deepfakes: Survey, battleground, and horizon," *Int J Comput Vis*, vol. 130, no. 7, pp. 1678–1734, 2022.
- [20] N. Sandotra and B. Arora, "A comprehensive evaluation of feature-based AI techniques for deepfake detection," *Neural Comput Appl*, vol. 36, no. 8, pp. 3859–3887, 2024.
- [21] A. S. Güneş and S. Vatansever, "A Survey of Source Camera Attribution Applications Using PRNU," in *2023 Innovations in Intelligent Systems and Applications Conference (ASIYU)*, 2023, pp. 1–6.
- [22] J. Lukas, J. Fridrich, and M. Goljan, "Digital camera identification from sensor pattern noise," *IEEE Transactions on Information Forensics and Security*, vol. 1, no. 2, pp. 205–214, 2006.
- [23] M. Koopman, A. M. Rodriguez, and Z. Geradts, "Detection of deepfake video manipulation," in *The 20th Irish machine vision and image processing conference (IMVIP)*, 2018, pp. 133–136.
- [24] D. Cozzolino, G. Poggi, and L. Verdoliva, "Recasting residual-based local descriptors as convolutional neural networks: an application to image forgery detection," in *Proceedings of the 5th ACM workshop on information hiding and multimedia security*, 2017, pp. 159–164.
- [25] B. Bayar and M. C. Stamm, "A deep learning approach to universal image manipulation detection using a new convolutional layer," in *Proceedings of the 4th ACM workshop on information hiding and multimedia security*, 2016, pp. 5–10.
- [26] P. Zhou, X. Han, V. I. Morariu, and L. S. Davis, "Two-stream neural networks for tampered face detection," in *2017 IEEE conference on computer vision and pattern recognition workshops (CVPRW)*, 2017, pp. 1831–1839.
- [27] C. Szegedy, S. Ioffe, V. Vanhoucke, and A. Alemi, "Inception-v4, inception-resnet and the impact of residual connections on learning," in *Proceedings of the AAAI conference on artificial intelligence*, 2017.
- [28] D. Afchar, V. Nozick, J. Yamagishi, and I. Echizen, "Mesonet: a compact facial video forgery detection network," in *2018 IEEE international workshop on information forensics and security (WIFS)*, 2018, pp. 1–7.
- [29] H. H. Nguyen, J. Yamagishi, and I. Echizen, "Use of a Capsule Network to Detect Fake Images and Videos," *arXiv preprint arXiv:1910.12467*, 2019.

- [30] F. Chollet, "Xception: Deep learning with depthwise separable convolutions," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 1251–1258.
- [31] H. Qi *et al.*, "DeepRhythm: Exposing deepfakes with attentional visual heartbeat rhythms," in *Proceedings of the 28th ACM international conference on multimedia*, 2020, pp. 4318–4327.
- [32] S. Waseem, S. R. Abu-Bakar, B. A. Ahmed, Z. Omar, T. A. E. Eisa, and M. E. E. Dalam, "DeepFake on Face and Expression Swap: A Review," *IEEE Access*, 2023.
- [33] S. McCloskey and M. Albright, "Detecting GAN-generated imagery using saturation cues," in *2019 IEEE international conference on image processing (ICIP)*, 2019, pp. 4584–4588.
- [34] Y. Huang *et al.*, "Fakepolisher: Making deepfakes more detection-evasive by shallow reconstruction," in *Proceedings of the 28th ACM international conference on multimedia*, 2020, pp. 1217–1226.
- [35] K. Patil, S. Kale, J. Dhokey, and A. Gulhane, "Deepfake detection using biological features: a survey," *arXiv preprint arXiv:2301.05819*, 2023.
- [36] M. Korkmaz and S. Vatansever, "Videolardan Kalp Atış Hz Kestirimi Üzerine Bir İnceleme," *Avrupa Bilim ve Teknoloji Dergisi*, no. 44, pp. 65–73, 2022.
- [37] P. V. Rouast, M. T. P. Adam, R. Chiong, D. Cornforth, and E. Lux, "Remote heart rate measurement using low-cost RGB face video: a technical literature review," *Front Comput Sci*, vol. 12, pp. 858–872, 2018.
- [38] Y. Deng and A. Kumar, "Standoff heart rate estimation from video: A review," *Mobile Multimedia/Image Processing, Security, and Applications 2020*, vol. 11399, pp. 16–29, 2020.
- [39] Y. Ni, W. Zeng, P. Xia, G. S. Yang, and R. Tan, "A Deepfake Detection Algorithm Based on Fourier Transform of Biological Signal," *Computers, Materials & Continua*, vol. 79, no. 3, 2024.
- [40] U. A. Çiftçi, İ. İlke Demir, and L. Yin, "Deepfake source detection in a heart beat," *Vis Comput*, vol. 40, no. 4, pp. 2733–2750, 2024.
- [41] J. Wu, Y. Zhu, X. Jiang, Y. Liu, and J. Lin, "Local attention and long-distance interaction of rPPG for deepfake detection," *Vis Comput*, vol. 40, no. 2, pp. 1083–1094, 2024.
- [42] W. Wang, "Robust and automatic remote photoplethysmography," 2017.
- [43] A. Malik, M. Kuribayashi, S. M. Abdullahi, and A. N. Khan, "DeepFake detection for human face images and videos: A survey," *Ieee Access*, vol. 10, pp. 18757–18775, 2022.
- [44] H. Alqahtani, M. Kavakli-Thorne, and G. Kumar, "Applications of generative adversarial networks (gans): An updated review," *Archives of Computational Methods in Engineering*, vol. 28, pp. 525–552, 2021.
- [45] V. Attari and R. Arroyave, "Machine learning-assisted high-throughput exploration of interface energy space in multi-phase-field model with CALPHAD potential," *Materials Theory*, vol. 6, no. 1, p. 5, 2022.
- [46] E.-G. Lee, I. Lee, and S.-B. Yoo, "ClueCatcher: Catching Domain-Wise Independent Clues for Deepfake Detection," *Mathematics*, vol. 11, no. 18, p. 3952, 2023.
- [47] X. Zhang, S. Karaman, and S.-F. Chang, "Detecting and simulating artifacts in gan fake images," in *2019 IEEE international workshop on information forensics and security (WIFS)*, 2019, pp. 1–6.
- [48] U. A. Ciftci, I. Demir, and L. Yin, "Fakecatcher: Detection of synthetic portrait videos using biological signals," *IEEE Trans Pattern Anal Mach Intell*, 2020.
- [49] W. Wang, A. C. Den Brinker, S. Stuijk, and G. De Haan, "Algorithmic principles of remote PPG," *IEEE Trans Biomed Eng*, vol. 64, no. 7, pp. 1479–1491, 2016.